UNIVERSIDAD PRIVADA DE TACNA · FACULTAD DE INGENIERÍA · ESCUELA DE INGENIERÍA DE SISTEMAS

Curso: Sistemas Operativos I · Unidad II · Noviembre de 2026 · Tacna – Perú

Diseño de la solución tecnológica: aplicación web de asistencia documental con RAG y MCP integrada con ProjectSevera

Proyecto de Unidad: “Chat bot RAG-MPC” · Docente: Dr. Renzo Alberto Taco Coayla

EQUIPO DE PROYECTO

Matteo Alejandro Cutipa Peralta · Milagros Condori Acero · Mario Eduardo Gomez Mamani · Geovani Jesus Lajo Zuela · Emerson Adilson Pariguana Yujra · Andre Fernando Valdez Fernandez

Asistencia documental y herramientas operativas (Anthropic, 2024; Lewis et al., 2020; Model Context Protocol, 2025)

SECCIÓN 1 · SÍNTESIS DE LA PROPUESTA

1. Resumen Ejecutivo

Consulta documental: Preguntas en lenguaje natural sobre manuales PDF.

Evidencia RAG: Recuperación previa a la respuesta (Lewis et al., 2020).

Protocolo MCP: Herramientas autorizadas de solo lectura (Anthropic, 2024; Model Context Protocol, 2025).

Backend Java: Arquitectura hexagonal con Spring Boot en MATTEO-01.

Motor IA local: ProjectSevera con FastAPI y PyTorch en MATTEOXPC.

Alcance Verificable en Unidad III

Comunicación privada mediante VPN Tailscale sin base relacional ni clúster empresarial innecesario.

4 casos de uso · 8 requerimientos funcionales · 11 requerimientos no funcionales medibles.

La disponibilidad de ProjectSevera depende del equipo local; las métricas de latencia, calidad y recuperación se verificarán en la Unidad III.

SECCIÓN 2.1 Y 2.2 · DIAGNÓSTICO ACADÉMICO VERIFICABLE

2. Planteamiento del Problema

2.1 Situación Actual y Límites

Dispersión técnica: Consultas dependientes de múltiples secciones (Feng et al., 2020; Feng et al., 2021).

Brecha léxica: Lenguaje coloquial frente a códigos exactos (Robertson y Zaragoza, 2009).

Recuperación mixta: Ninguna técnica única domina siempre (Karpukhin et al., 2020; L. Gao et al., 2023; Muennighoff et al., 2023).

Fidelidad generativa: Comandos inventados y pérdida intermedia (Adlakha et al., 2024; Ji et al., 2023; Shuster et al., 2021).

2.2 Necesidades Identificadas

Atribución de fuentes: Correspondencia entre afirmación y evidencia (Friel et al., 2024; Saad-Falcon et al., 2024; T. Gao et al., 2023).

Indexación externa: Actualizar PDF sin reentrenar parámetros (Guu et al., 2020; Lewis et al., 2020; Y. Gao et al., 2024).

Lectura operativa: Consultar estado sin privilegios administrativos generales.

Control de herramientas: Mitigar fallos de selección y autorización (Li et al., 2023; Schick et al., 2023; Yao et al., 2023).

Nota metodológica: Entorno académico controlado; no se atribuyen métricas empresariales ni tickets no medidos.

SECCIÓN 2.3 Y SECCIÓN 3 · FUNDAMENTACIÓN Y METAS DE DISEÑO

2.3 Justificación y 3. Objetivos

Objetivo General: Diseñar una aplicación web basada en RAG y MCP para consultar PDF en lenguaje natural con respuestas citadas, backend Java hexagonal en Azure y ProjectSevera local.



OE-1 y OE-2: Gestión y RAG

Respuestas sustentadas o abstención (Asai et al., 2024; Es et al., 2024; Yan et al., 2024).



OE-3: Integración MCP

Permisos validados en servidor (Hasan et al., 2025; Hou et al., 2026; Model Context Protocol, 2025).



OE-4: Arquitectura y Red

Puertos y adaptadores modulares (Cockburn, 2005; Y. Gao et al., 2024).

Los archivos del RAG y las respuestas de herramientas se tratan como datos de menor confianza frente a instrucciones maliciosas (Debenedetti et al., 2024; Greshake et al., 2023; Zhan et al., 2024).

SECCIÓN 4.1 Y 4.2 · TABLAS 1 Y 2 DEL INFORME

4. Casos de Uso y Requerimientos

ID RF	Caso de Uso Asociado	Actor	Capacidad Funcional Comprometida
RF-01	CU-01 Consultar IA	Usuario / Admin	Consultas en lenguaje natural sin registro
RF-02	CU-01 Consultar IA	Usuario / Admin	Recuperar fragmentos e identificar PDF origen (T. Gao et al., 2023)
RF-03	CU-01 Consultar IA	Usuario / Admin	Informar insuficiencia de evidencia (Adlakha et al., 2024; Asai et al., 2024)
RF-04	CU-02 Gestionar doc.	Administrador	Cargar archivos PDF y consultar listado
RF-05	CU-02 Gestionar doc.	Administrador	Eliminar PDF y retirar fragmentos del índice
RF-06	CU-02 Gestionar doc.	Administrador	Estados pendiente, procesado, error o eliminado
RF-07	CU-03 Herramientas MCP	Usuario / Admin	Extensión CU-01: lectura MCP (Model Context Protocol, 2025; Yao et al., 2023)
RF-08	CU-04 Iniciar sesión	Administrador	Autenticar y cerrar sesión administrativa

Generar una respuesta fundamentada (RF-02) y reconocer la insuficiencia de evidencia (RF-03) se evalúan por separado (Adlakha et al., 2024; Asai et al., 2024).

SECCIÓN 4.3 · ATRIBUTOS DE CALIDAD Y UMBRALES (TABLA 3)

4.3 Calidad (ISO/IEC 25010:2023)

RNF-01, RNF-02, RNF-03 y RNF-09: Seguridad e Interoperabilidad Java–Python (ISO/IEC, 2023) (10/10 = 100%)



RNF-06 Eficiencia: Al menos 18 de 20 consultas RAG en ≤ 60 s con 1 usuario concurrente (90%)



RNF-11 Adecuación Funcional: Sustentar en evidencia ≥ 16 de 20 respuestas (Es et al., 2024; Friel et al., 2024; Saad-Falcon et al., 2024) (80%)



Umbrales adicionales: RNF-04 Tolerancia a fallos (aviso caída Severa ≤ 10 s en 5 ensayos) · RNF-05 Respaldo diario PDF/JSON · RNF-07 Operabilidad (≤ 3 acciones) · RNF-08 Modificabilidad (adaptador simulado sin tocar Domain) · RNF-10 Escalabilidad (≥ 20 PDF).

La fidelidad al contexto y la corrección de la respuesta se registran como dimensiones distintas sobre preguntas de referencia (Es et al., 2024; Friel et al., 2024; Saad-Falcon et al., 2024).

SECCIÓN 5.1 · PUERTOS, ADAPTADORES Y DOMINIO (FIGURA 2)

5.1 Arquitectura Lógica Hexagonal

CAPA 1 · ENTRADA

Infrastructure (Entrada)

ChatController público y DocumentController protegido con cuenta ADMIN en memoria mediante InMemoryUserDetailsManager y BCrypt (Spring Security, s. f.).

CAPA 2 · NÚCLEO

Domain y Application

Document y ConversationContext; AskQuestionUseCase, ManageDocumentUseCase y QueryMcpToolUseCase sobre puertos estables (Cockburn, 2005; ISO/IEC, 2023).

CAPA 3 · SALIDA

Infrastructure (Salida)

Componentes del backend Java: PythonAiAdapter (hacia Severa por Tailscale), FileDocumentRepositoryAdapter (PDF y metadata.json) y McpClientAdapter.

La aplicación desconoce las librerías internas de ProjectSevera; su desacoplamiento se comprobará con un adaptador simulado según RNF-08 (Cockburn, 2005).

5.2 Despliegue Físico y Componentes

Dos Nodos Conectados por VPN Tailscale

MATTEO-01 (Azure): Standard B2as v2 (2 vCPU, 8 GiB RAM), Windows Server 2022, IIS HTTPS:443, Spring Boot :8080, MCP, PDF y metadata.json (Microsoft, s. f.).

MATTEOXPC (Local): Intel Core i7-14700F, 64 GB RAM y RTX 5070 Ti para búsqueda vectorial e inferencia GPU (Johnson et al., 2021; Malkov y Yashunin, 2020).

Sin infraestructura ficticia: No se usan 3 servidores, PostgreSQL ni Proxmox.

Decisiones de Indexación y Flujo MCP

Granularidad experimental: Segmentación y vectorización con ID y versión (Barnett et al., 2024; Chen et al., 2024).

Línea base vectorial: Índice persistente frente a DPR, ColBERT, BM25, reranking o GraphRAG (Edge et al., 2024; Izacard y Grave, 2021; Karpukhin et al., 2020; Khattab y Zaharia, 2020; Nogueira et al., 2020; Robertson y Zaragoza, 2009).

MCP cerrado: getDocumentIndexStatus y getServiceStatus (Hou et al., 2026; Jiang et al., 2023; Qin et al., 2024).

Mostrar una cita no basta: se verificará que el pasaje recuperado sustente realmente la afirmación generada (Adlakha et al., 2024; Ji et al., 2023; T. Gao et al., 2023).

6. Infraestructura y Sincronización

Cada registro en **metadata.json** conserva identificador, huella SHA-256, versión y estado para controlar errores de extracción y fragmentación (Barnett et al., 2024; Chen et al., 2024; Feng et al., 2021):

1. Pendiente

Carga esperando procesamiento local.

2. Procesado

Fragmentos vectorizados en índice.

3. Error

Fallo identificado para reintento.

4. Eliminado

Fragmentos retirados del buscador.

El dimensionamiento de almacenamiento y GPU se medirá con 20 PDF de muestra y un usuario concurrente (Johnson et al., 2021; Microsoft, s. f.; Muennighoff et al., 2023).

SECCIÓN 7 · SEGMENTACIÓN LÓGICA, DIRECCIONAMIENTO Y REGLAS (TABLAS 7 Y 8)

7. Diseño de Red y Reglas Firewall

VM Azure **172.16.0.4** (**vnet-chilecentral-1 / snet-chilecentral-1**), Spring Boot en **127.0.0.1:8080** y FastAPI en **IP Tailscale:8000** sin VLAN físicas IEEE 802.1Q (Microsoft, s. f.; Tailscale, s. f.).

ID	Origen	Destino / Servicio	Acción y Control
FW-01	Internet	IIS Azure TCP 443	Permitir entrada HTTPS pública
FW-02	Internet	Spring Boot 8080 / MCP	No publicar / denegar (solo loopback)
FW-03	Internet	FastAPI PC TCP 8000	No publicar / denegar en firewall local
FW-04	Tailscale Azure	API PC TCP 8000	Permitir solo equipo autorizado (Tailscale, s. f.)
FW-05	Admin autorizado	RDP Azure TCP 3389	Restringir por VPN o IP autorizada (NIST, 2020)
FW-06	Cualquier otro origen	Servicios internos	Denegar entrada por defecto

Ningún secreto de Tailscale, cookie de sesión o credencial administrativa se expondrá en capturas públicas (NIST, 2020; Tailscale, s. f.).

8. Seguridad y Riesgos (ISO 27005)

Amenazas Valoradas (P × I de 1 a 9)

R-01 (P2×I3=6 Alto): Acceso indebido a administración (ISO/IEC, 2022).

R-02 (P2×I3=6 Alto): Prompt injection desde PDF (Debenedetti et al., 2024; Greshake et al., 2023; Zhan et al., 2024).

R-03 (P2×I3=6 Alto): Invocación MCP sin permiso (Hasan et al., 2025; Hou et al., 2026).

R-05 y R-07 (Nivel 6 Alto): Exposición pública o caída PC/VPN.

R-04 y R-06 (P2×I2=4 Medio): Archivo inválido o pérdida PDF/JSON.

Controles E-01 a E-05 y Contingencia

E-01 y E-02: ADMIN en memoria con BCrypt, validación PDF y datos separados de instrucciones (Spring Security, s. f.).

E-03 y E-04: Allowlist MCP solo lectura en Java/servidor, NSG, Tailscale y control de tasa.

E-05 Respaldo (CP-9): Copia externa diaria (7 copias, pérdida máxima ≤ 24 h) (ISO/IEC, 2022; NIST, 2020).

Auditoría básica: Logs con código de rastreo sin contraseñas ni tokens (NIST, 2020).

La defensa separa los datos recuperados de las instrucciones privilegiadas y valida permisos del lado servidor (Debenedetti et al., 2024; NIST, 2020).

9. Operación, Matriz RACI y Fallos

9.1 Responsabilidades RACI

Alta y baja de PDF: Admin (A/R), Backend/IA (C), Infra (I).

Cambio de adaptadores: Backend (A/R), IA/Infra (C), Admin (I).

Modelo e índice RAG: IA (A/R), Backend/Infra (C), Admin (I).

Firewall, VPN y respaldos: Infraestructura (A/R).

Revisión conjunta: Backend (A/R) e IA (R).

9.4 Respuesta ante Incidentes

Spring Boot caído: Revisar puerto/logs, reiniciar y probar consulta.

Severa no disponible: Verificar PC/VPN e informar caída sin fingir.

Índice desactualizado: Comparar metadata.json y reprocesar ID.

Archivo perdido: Restaurar último respaldo y verificar lectura.

MCP denegado: Mantener rechazo sin relajar reglas (NIST, 2020).

El mantenimiento preventivo semanal vigila tanto los puntos de fallo en datos RAG como las herramientas MCP (Barnett et al., 2024; Hasan et al., 2025; Hou et al., 2026).

SECCIÓN 10 Y SECCIÓN 11 · CRONOGRAMA UNIDAD III (TABLA 14) Y BATERÍA PF/PN (TABLAS 15 Y 16)

10. Implementación y 11. Pruebas

16-22 NOV. 2026

F1. Preparación

Azure, HTTPS, VPN, FastAPI y repositorio.

23-29 NOV. 2026

F2. Núcleo Funcional

PDF/JSON, indexación, CU-01 y citas.

30 NOV.-3 DIC. 2026

F3. Integración

MCP, ADMIN, controles, logs y copias.

4-6 DIC. 2026

F4. Validación

Pruebas RF/RNF, seguridad y restauración.

Plan de Pruebas (PF-01 a PF-08 y PN-01 a PN-11): Evaluación incremental y conductual con 20 PDF y 20 preguntas de referencia (5 directas, 5 léxicas, 5 multidocumento y 5 fuera del corpus) junto con métricas de fidelidad (Adlakha et al., 2024; Es et al., 2024; Friel et al., 2024; Hou et al., 2026; Ribeiro et al., 2020; Saad-Falcon et al., 2024; Y. Gao et al., 2024).

Las pruebas adversariales evalúan inyección indirecta desde PDF y caídas deliberadas de Severa/Tailscale (Debenedetti et al., 2024; Greshake et al., 2023; Zhan et al., 2024).

SECCIÓN 12 · FACTIBILIDAD TÉCNICA, ECONÓMICA (TABLAS 17 Y 18) Y OPERATIVA

12. Análisis de Factibilidad

S/ 342,00

Azure IaaS mensual (US$100 × S/3,42)

S/ 518,40

Electricidad PC media (0,9 kW · 648 kWh)

S/ 985,40

Total mensual orientativo (S/860,40 sin trabajo)

Escenarios eléctricos (720 h a S/0,80/kWh): 0,6 kW (432 kWh = S/345,60), 0,9 kW (648 kWh = S/518,40) y 1,2 kW (864 kWh = S/691,20), sujeto a tarifas de nube (Microsoft, s. f.).

Valoración de esfuerzo: Referencia junior S/15,625/h (S/2.500 / 160 h); dedicación inicial 60 h = S/937,50 y mantenimiento 8 h = S/125,00/mes.

Viabilidad técnica y operativa: Desempeño de GPU y tutoría documental evaluados en horarios de laboratorio (Barrionuevo-Valenzuela et al., 2026; ISO/IEC, 2023; Johnson et al., 2021; Modran, 2025; Muennighoff et al., 2023).

El análisis distingue desembolso efectivo y costo de oportunidad sin inventar VAN, TIR ni ahorros empresariales no medidos.

SECCIÓN 13 Y SECCIÓN 14 · CIERRE DEL PROYECTO Y SUSTENTO BIBLIOGRÁFICO

13. Conclusiones y 14. Referencias

Síntesis de Conclusiones (Sección 13)

Delimitación verificable: Separación entre RAG documental y MCP de lectura con 4 CU, 8 RF y 11 RNF (Lewis et al., 2020; Model Context Protocol, 2025).

Desacoplamiento: Arquitectura hexagonal entre Azure (MATTEO-01) y MATTEOXPC (ProjectSevera) vía Tailscale (Cockburn, 2005).

Rigor en Unidad III: Seguridad, sincronización, respaldos y rendimiento sujetos a evidencia de pruebas reales (ISO/IEC, 2022, 2023; NIST, 2020).

Referencias Bibliográficas (Sección 14)

Adlakha et al. (2024) · Anthropic (2024) · Asai et al. (2024) · Barnett et al. (2024) · Barrionuevo-Valenzuela et al. (2026) · Chen et al. (2024) · Cockburn (2005) · Debenedetti et al. (2024) · Edge et al. (2024) · Es et al. (2024) · Feng et al. (2020, 2021) · Friel et al. (2024) · L. Gao et al. (2023) · T. Gao et al. (2023) · Y. Gao et al. (2024) · Greshake et al. (2023) · Guu et al. (2020) · Hasan et al. (2025) · Hou et al. (2026) · ISO/IEC (2022, 2023) · Izacard y Grave (2021) · Ji et al. (2023) · Jiang et al. (2023) · Johnson et al. (2021) · Karpukhin et al. (2020) · Khattab y Zaharia (2020) · Lewis et al. (2020) · Li et al. (2023) · Malkov y Yashunin (2020) · Microsoft (s. f.) · Model Context Protocol (2025) · Modran (2025) · Muennighoff et al. (2023) · NIST (2020) · Nogueira et al. (2020) · Qin et al. (2024) · Ribeiro et al. (2020) · Robertson y Zaragoza (2009) · Saad-Falcon et al. (2024) · Schick et al. (2023) · Shuster et al. (2021) · Spring Security (s. f.) · Tailscale (s. f.) · Yan et al. (2024) · Yao et al. (2023) · Zhan et al. (2024).

Repositorio y estructura: https://adi-upt.github.io/FUENTE-SOI/#estructura

¡Muchas gracias por su atención! · Preguntas y Sustentación Técnica